

Relatorio final - Atelie Generativo

Projeto: atelie-generativo-felipe-santiago

Responsavel: Felipe Santiago

Estilo: Xilogravura Digital do Cerrado

Token textual: flpxilobr

Modelo base: stable-diffusion-v1-5/stable-diffusion-v1-5

Space publico:

<https://huggingface.co/spaces/RalphError/atelie-xilogravura-cerrado>

App: <https://ralpherror-atelie-xilogravura-cerrado.hf.space>

1. Introducao e escolha do estilo

O Atelie Generativo desenvolve um pipeline multimodal no qual um tema curto informado pelo usuario e expandido por um modelo de linguagem, convertido em imagem por Stable Diffusion com LoRA e narrado por um sistema TTS em portugues. O objetivo academico foi construir, treinar, avaliar e publicar uma experiencia completa de geracao de texto, imagem e audio, mantendo rastreabilidade de dados, seguranca de credenciais e reflexao etica.

O estilo escolhido foi Xilogravura Digital do Cerrado, descrito em config/project.json como uma linguagem visual inspirada em caracteristicas gerais da xilogravura brasileira: contornos pretos marcantes, alto contraste, hachuras artesanais, formas simplificadas e paleta reduzida, aplicada a animais, plantas, paisagens, objetos e cenas cotidianas do Cerrado brasileiro. A proposta evita imitar artista vivo identificavel e usa o token flpxilobr para ativar o estilo nos prompts.

O projeto e individual. Felipe Santiago aparece como responsavel por dados e licencas, treinamento LoRA, avaliacao, aplicacao/publicacao e documentacao. A aprovacao do estilo foi registrada no arquivo de configuracao como confirmada pelo responsavel humano em 2026-07-10.

2. Dataset, proveniencia e licencas

O dataset final contem 24 imagens em dados/imagens/, dentro do intervalo exigido de 20 a 40 imagens. A proveniencia esta registrada em dados/fontes.csv, com arquivo, URL, autor, licenca, data de coleta, fonte e observacoes. As fontes vieram do Wikimedia Commons e usam licencas CC-BY-SA nas versoes 2.0, 3.0 ou 4.0, todas aceitas pelo contrato do projeto.

As imagens finais sao derivacoes deterministicas locais das fontes originais. O processamento usou Pillow, sem modelo generativo e sem prompt de transformacao, para produzir uma versao em preto e marfim com recorte, contraste e hachuras. Essa decisao foi registrada em docs/DECISIONS.md como ADR-010, diferenciando claramente uma edicao tecnica local de uma geracao por IA.

As captions finais estao em dados/legendas.txt e foram revisadas com o token flpxilobr no inicio. O arquivo dados/metadata.jsonl foi exportado somente depois da confirmacao humana de revisao das captions, conforme ADR-011. A auditoria do dataset esta documentada em resultados/auditorias/dataset_final_2026-07-11.md e resultados/auditorias/dataset_validacao_final_2026-07-11.json.

3. Metodologia de captions e revisao humana

A legenda de cada imagem foi escrita para cumprir dois papeis: descrever o conteudo visual e reforcar o estilo aprendido pelo LoRA. Todas as captions comecam com flpxilobr, e incluem elementos semanticos do Cerrado, como vegetacao, fauna, rochas, paisagens, flores e texturas graficas. O uso do token cria um ponto de ancoragem textual para o treinamento e tambem facilita a comparacao entre modelo base e modelo adaptado.

A revisao humana foi tratada como portao obrigatorio. O projeto nao declara captions como concluidas apenas por processamento automatico; a confirmacao foi registrada antes da exportacao do metadata de treino. Essa escolha reduz o risco de treinar o modelo com descricoes imprecisas ou desalinhadas com o tema visual.

4. Fine-tuning LoRA e comparacao de configuracoes

O treinamento utilizou o modelo base `stable-diffusion-v1-5/stable-diffusion-v1-5` e o script oficial `examples/text_to_image/train_text_to_image_lora.py` do Diffusers, no commit `01969142b55379991fee07608c9e7e8f80afced0`. O dataset hash registrado foi `7e34d52d32ae06c83440d8dc176ea7ad472980b1380d1972c297d5ab6dabec31`, com seed 1337 e resolucao 512.

Foram treinadas duas configuracoes comparaveis:

Configuracao	Rank	Learning rate	Max steps	Status	Checkpoint
config_a	4	0.0001	1000	concluido	resultados/treino/local/config_a/checkpoint-1000
config_b	8	0.00005	1500	concluido	resultados/treino/local/config_b/checkpoint-1500

A configuracao escolhida para o app foi `config_b`. A escolha priorizou um adaptador com maior capacidade, mais passos de treino e learning rate menor, mantendo o mesmo dataset, seed e modelo base. Os registros completos estao em `resultados/treino/experimentos.csv`. O arquivo de pesos usado pelo app fica em `resultados/treino/local/config_b/pytorch_lora_weights.safetensors` e tambem foi empacotado no Space publicado.

5. Avaliacao base versus LoRA

A avaliacao usou 6 prompts fixos em `dados/prompts_avaliacao.txt`, seed de geracao 2026, modelo CLIP `openai/clip-vit-base-patch16` e comparacao entre modelo base e LoRA `config_b`. A grade visual esta em `resultados/avaliacao/grade_comparativa.png`.

5.1 CLIPScore

O arquivo `resultados/avaliacao/clipscore.csv` contem 12 linhas, correspondendo aos 6 prompts avaliados nos dois modelos. O resumo em `resultados/avaliacao/clipscore_resumo.csv` registra:

Modelo	Media	Desvio padrao	Minimo	Maximo
Base	26.786041	3.690527	22.258356	32.782775
config_b	23.273084	3.042174	19.779481	28.824174

O CLIPScore foi usado como indicador auxiliar de alinhamento texto-imagem, não como medida isolada de qualidade estética. No caso deste projeto, a média do modelo base foi maior, enquanto a avaliação humana preferiu majoritariamente as imagens LoRA. Esse contraste reforça que métricas automáticas precisam ser interpretadas junto com avaliação visual e critérios de estilo.

5.2 Avaliação humana cega

A avaliação humana está em resultados/avaliacao/avaliacao_humana.csv. Foram registrados 5 avaliadores únicos (F01, L01, M01, R01, W01) e 30 respostas. As preferências agregadas foram 20 escolhas para B e 10 para A. A média de aderência ao estilo foi 4.6 e a média de qualidade foi 4.7 em escala de 1 a 5.

Os identificadores são pseudônimos. O projeto não inclui nomes reais de avaliadores no relatório, preservando privacidade e minimização de dados pessoais.

5.3 Memorização e overfitting

Foram executados 10 testes de memorização em resultados/avaliacao/memorizacao.csv, comparando imagens geradas com imagens de treino mais próximas por similaridade CLIP. O resultado classificou 7 casos como risco baixo e 3 como risco médio. A maior similaridade registrada foi 0.919870.

Como o próprio arquivo de avaliação observa, similaridade CLIP não prova cópia. Os casos de risco médio devem ser revisados visualmente sempre que o modelo for reutilizado ou publicado em um contexto com exigência maior de originalidade.

6. Arquitetura do pipeline multimodal

O app Gradio implementa o contrato:

```
tema curto -> expensor de prompt -> Stable Diffusion + LoRA -> TTS -> interface com  
texto, imagem e audio
```

Os provedores finais estão separados em app/services/:

- LocalQwenPromptExpander: usa Qwen/Qwen2.5-0.5B-Instruct para expandir o tema em português e manter o token flpxilobr.

- LocalLoRAImageGenerator: carrega Stable Diffusion v1.5 e aplica explicitamente os pesos LoRA config_b.
- MMSSpeechSynthesizer: usa facebook/mms-tts-por para gerar narracao em portugues.

O smoke test local em resultados/app_smoke_v3/smoke_report.json executou tres temas com saidas completas de prompt, imagem PNG e audio WAV. As latencias locais registradas foram 35.086 s, 15.301 s e 14.098 s.

7. Publicacao e seguranca

O Space publico foi criado em RalphError/atelie-xilogravura-cerrado. A evidencia registrada em resultados/auditorias/space_teste_anonimo_2026-07-11.md mostra duas execucoes anonimas completas, com prompt, imagem e audio. A segunda execucao remota registrada levou 257.671 s, indicando que o Space em CPU Basic funciona, mas tem latencia alta para demonstracao ao vivo.

O token Hugging Face nao foi gravado no repositorio. A configuracao exige HF_TOKEN apenas em variavel de ambiente local ou Secret do Space. O comando scripts/check_secrets.py foi usado para verificar ausencia de padroes de segredo.

8. Reflexao etica e juridica

O projeto usa imagens de licenca aberta e registra autoria, URL e licenca por item. Como ha imagens CC-BY-SA, a manutencao de atribuicoes e compatibilidade de compartilhamento e parte central da entrega. A Lei 9.610/1998 e considerada no sentido de respeitar autoria, titularidade e limites de uso de obras protegidas; por isso, o projeto evita fonte sem licenca clara, personagens de propriedade intelectual e imitacao de artista vivo identificavel.

Quanto a LGPD, o dataset visual nao usa pessoas reais identificaveis como foco do treinamento. A avaliacao humana usa identificadores pseudonimos e nao inclui nomes reais no relatorio. A coleta de opinioes foi limitada ao necessario para comparar preferencias, aderencia ao estilo e qualidade percebida.

Os principais riscos restantes são: reproduzir vieses das fontes abertas, induzir falsa impressão de autoria manual, superestimar CLIPScore como qualidade final e reutilizar saídas sem revisar possível proximidade com imagens do dataset. Para mitigar esses riscos, o projeto documenta origem, licenças, limitações, testes de memorização e uso de IA assistiva.

9. Limitações e trabalhos futuros

As limitações principais são:

- o dataset é pequeno, com 24 imagens, adequado para um experimento LoRA acadêmico, mas insuficiente para cobrir toda a diversidade visual do Cerrado;
- o Space em CPU Basic tem latência alta, especialmente na primeira execução e em inferência de imagem;
- a avaliação humana tem 5 avaliadores, o mínimo exigido, mas ainda é pequena para conclusões estatísticas amplas;
- o CLIPScore favoreceu o modelo base, enquanto avaliadores preferiram mais vezes a alternativa B, o que mostra tensão entre métrica automática e critério estético;
- a similaridade CLIP dos testes de memorização apontou 3 casos de risco médio que devem continuar sendo revisados visualmente.

Trabalhos futuros incluem ampliar o dataset com mais fontes CC0/CC-BY, testar Space com GPU temporária ou endpoint externo, publicar um repositório LoRA dedicado com model card completo e repetir avaliação humana com mais participantes.

10. Declaração de uso de IA

O projeto utilizou ChatGPT/Codex como assistente de engenharia, revisão, documentação, depuração de notebooks, preparação de scripts, análise de erros, apoio na publicação do Space e consolidação deste relatório. A equipe humana permanece responsável por decisões, aprovação de estilo, revisão de captions, configuração de secrets, avaliação humana real, interpretação de resultados e entrega final.

O registro incremental está em docs/AI_ASSISTANCE.md.

11. Demonstração e plano de contingência

Para o Demo Day, o fluxo principal é abrir o Space público e executar um tema curto e seguro, como seriema ao amanhecer no Cerrado ou flores de pequi e buritis. Como a latência remota em CPU Basic pode ultrapassar quatro minutos, o plano de contingência é apresentar:

- resultados/app_smoke_v3/, com três execuções locais completas;
- resultados/avaliacao/grade_comparativa.png, para demonstrar comparação visual base versus LoRA;
- os audios WAV gerados no smoke local;
- a evidência resultados/auditorias/space_teste_anonimo_2026-07-11.md, deixando claro que se trata de contingência e não de execução ao vivo.

12. Evidências principais

Item | Evidência

Configuração do projeto | config/project.json

Proveniência e licenças | dados/fontes.csv

Captions revisadas | dados/legendas.txt

Metadata de treino | dados/metadata.jsonl

Experimentos LoRA | resultados/treino/experimentos.csv

Grade comparativa | resultados/avaliacao/grade_comparativa.png

CLIPScore | resultados/avaliacao/clipscore.csv

Memorização | resultados/avaliacao/memorizacao.csv

Avaliação humana | resultados/avaliacao/avaliacao_humana.csv

Smoke test local | resultados/app_smoke_v3/smoke_report.json

Teste anônimo do Space | resultados/auditorias/space_teste_anonimo_2026-07-11.md

Referências

- BRASIL. Lei n. 9.610, de 19 de fevereiro de 1998. Lei de Direitos Autorais. Portal da Legislação.
- BRASIL. Lei n. 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais. Portal da Legislação.
- Hugging Face. stable-diffusion-v1-5/stable-diffusion-v1-5.
- Hugging Face. Qwen/Qwen2.5-0.5B-Instruct.
- Hugging Face. facebook/mms-tts-por.
- OpenAI. CLIP: Contrastive Language-Image Pre-training.
- Diffusers documentation and examples for text-to-image LoRA training.